Claude Code 协同 Stata：环境配置与应用实践

报告人：黎佳迅

中山大学岭南学院硕士研究生

2026.4.23

内容大纲

一、Stata 环境配置

二、Claude Code 基本交互技巧

三、用 Claude Code 清洗 CSMAR 企业财务数据

四、skill 简介和创建数据处理 skill

本次分享的内容手册链接：

> 本次分享涉及的全部资料：https://github.com/jasonli357/Claudecode_Stata
> 内容手册：https://jasonli357.github.io/Claudecode_Stata/
> 关于 Claude Code 的安装，可参考：
> https://jasonli357.github.io/Claudecode_Stata/body/11_references.html

一、Stata 环境配置

用 Claude Code 运行 Stata 会遇到什么问题?

1. Claude Code 不知道 Stata 安装在哪里

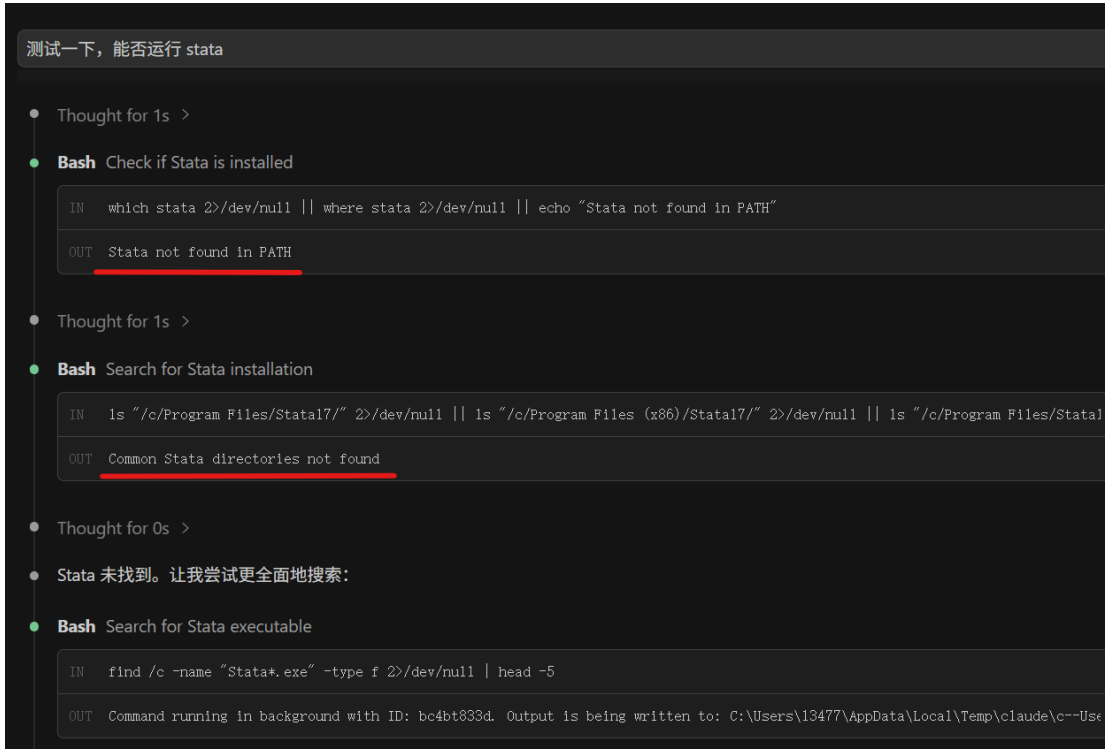

即使把 stata 放进环境路径里，有时还是找不到。

2. Claude Code 在终端调用 Stata 执行 dofile 时，可能用了错误的路径格式

如果 Claude Code 安装在 WSL，而 Stata 安装在 Windows 上，Claude Code 可能使用如下终端命令：

```
stata -b do /mnt/d/work/analysis.do  # /mnt/d/... 是 WSL 的路径格式
```

但 Windows 里的 Stata 只能识别 `D:/work/analysis.do` 这种路径格式

方案 1：在 `CLAUDE.md` 中设定 Stata 使用规则

CLAUDE.md 就是一个**项目级的"说明文件"**，Claude Code **每次启动时会自动读取**它。可以在 CLAUDE.md 写以下内容：

1. 说明 Stata 安装路径
2. 指定运行 dofile 的终端命令
3. 规定日志（.log）生成位置
    - 运行前需先 cd 到项目目录，否则日志会写到默认路径
4. 根据日志检测代码错误

方案 2：安装 Stata MCP（需要有 STATA.LIC）

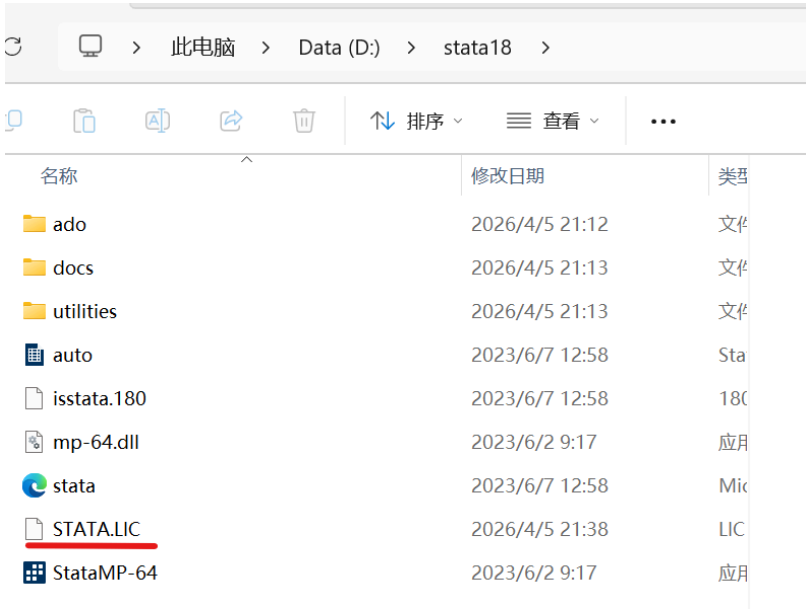

1. 在 VS Code 安装 Stata MCP 插件
2. 设置 Stata 安装路径（这一步完成后，VS Code 右下角会显示 "Stata: Connected"）
3. 在 Claude Code 添加 Stata MCP 服务器

```
claude mcp add --transport sse stata-mcp http://localhost:4000/mcp --scope user
```

Stata MCP 的功能

- 运行 .do 文件（`stata_run_file`）
- 运行代码片段（`stata_run_selection`）
- 支持多会话模式（可并行运行多个 Stata 实例）

> 既然 claude code 可以用【"/d/stata18/StataMP-64.exe" /e do "script.do"】这种命令行方式运行 stata，那 stata-mcp 还有什么意义?

- 命令行方式相当于每次运行都打开一个新的 stata 窗口，运行完 dofile 后自动关闭。
- Stata MCP 能让 AI 像我们平时和 Stata 交互一样，在同一个窗口内多次执行 stata 命令。

对比项	命令行 `/e`	stata-mcp
需要创建 `.do` 文件	是	否（用 `stata_run_selection` 工具直接运行代码片段）
结果获取	需手动读 log	直接返回
会话保持	每次全新启动	可复用同一会话
数据加载	每次重新加载	加载一次，后续复用

二、Claude Code 基本交互技巧

执行权限控制

- claude --dangerously-skip-permissions
- claude --permission-mode auto
  - 使用一个后台 AI 替你判断命令是否有风险
  - claude 官方模型 sonnet/opus 可用，GLM 等第三方模型不可用
- 在 `.claude\settings.json` 或 `.claude\settings.local.json` 里配置白名单，白名单里的命令不需要询问用户许可
  - 每次 claude code 询问是否允许某个操作时，如果选 "Yes, and don't ask again for ..."，ai 就会在 `.claude\settings.local.json` 的白名单里自动添加这个命令
  - 如果不确认添加某个命令是否有风险，可以在 AI 征求某个命令的许可之后，马上用 `/btw` 问问 AI。

发现、安装并管理官方及第三方技能包

1. 通过 `/plugin` 下载和管理
2. 直接用自然语言把网址发给 ai，让它下载
3. 手动下载网页上的 skill，移动到系统级或者项目级的 `.claude/skills` 文件夹
    - 系统级：`~/.claude`（Windows：`C:\Users\13477\.claude`）
    - 项目级：`/mnt/c/Users/13477/Desktop/claude_stata/.claude`

例子：
Anthropic 官方的 Skills 仓库：https://github.com/anthropics/skills.git

常用斜杠命令（Slash Commands）

- /resume：查看和恢复历史会话
- /btw：运行过程中对话，不打断当前进程；回答完自动消失，不污染上下文
- /branch：分支
- /rewind：回退
- /export：导出会话记录
- /insights：生成一份 HTML 报告，分析用户过去一个月使用 Claude Code 的习惯，给出使用建议

三、用 Claude Code 清洗 CSMAR 企业财务数据

任务：从企业基本信息和财务报表数据中，计算 5 个企业特征：公司规模（Size）、年龄（Age）、资产负债率（Lev）、营业收入增长率（Growth）、资产收益率（ROA）

Step 1：个人工作习惯和希望 AI 工作的方式，在 CLAUDE.md 里写明

- 通过 Stata-mcp 调用 Stata，不要用命令行。
- 原始数据在 `data/raw/` 目录下，不要修改或覆盖；清洗过程中以及清洗后的数据存入 `data/processed/`
- 代码放在 `code/`
- 说明文档放在 `file/`
- Stata MCP 运行在 Windows 端，必须使用 Windows 路径格式（`C:/Users/...`），不能用 WSL 的 `/mnt/c/...` 格式，否则报 `r(601) file not found`

> 完善 CLAUDE.md：可以在 AI 执行完任务后，问它刚刚有没有遇到问题。然后让它总结经验，写进 `CLAUDE.md` 里面。

```
> 刚刚有没有遇到什么问题或者报错？

● 有的，过程中遇到了几个问题，经过逐一排查才最终跑通：

  问题 1：中文路径无法识别
  Stata 无法读取含中文字符的路径（如 data/raw/利润表/FS_Comins.csv），报 r(601) file not found。解决办法是将四个 CSV 复制到 data/tmp/
  并重命名为纯英文名（info.csv、income.csv 等）。

  问题 2：Linux /tmp 路径不可访问
  最初把文件复制到 WSL 的 /tmp/stata_data/，但 Stata 实际运行在 Windows 端，无法访问 Linux 路径，同样报 r(601)。改为复制到项目的 data/tmp/
  目录并使用 C:/Users/... 风格路径后解决。

  问题 3：全局变量定义顺序错误
  代码中 $raw 引用了 $data，但 $data 在 $raw 之后才定义，导致 $raw 解析为空路径。调整顺序后修复。

  问题 4：变量名大小写不匹配
  import delimited 会将所有 CSV 列名转为小写（如 Stkcd → stkcd），但代码中直接用了大写的 Stkcd，导致 merge 时找不到变量报 r(111) variable not
   found。修正为导入后先 rename stkcd Stkcd 再使用。

✻ Worked for 36s

> stata应该是可以读取中文路径的，请你再检查一下

● 让我直接测试一下 Stata 能否读取中文路径。

● 你说得对，Stata 确实可以读取中文路径。之前报错 r(601) 的真正原因是第一个版本用了 Linux 风格路径 /mnt/c/...，而 Stata 运行在 Windows 上需要
  C:/... 格式。

  让我把 .do 文件改回直接使用原始中文路径，去掉 data/tmp/ 的中间步骤。
```

Step 2：打开 plan mode，具体说明任务需求（用什么工具、有哪些步骤、最后要输出什么），自己对需求不确定的地方也可以写明，让 AI 完善

【prompt】

```
【data/】里面是实证金融研究用的 A 股上市公司数据，需要清洗合并后计算常用控制变量
（Size、Age、Lev、Growth、ROA），对这些指标进行描述性统计。用 stata 完成。

注意事项：删除金融行业（行业代码J*）、计算出的指标要缩尾

- 我不确定具体要执行哪些数据清洗操作，需要你结合数据结构和数据处理的惯例判断

最后输出三个文件：处理数据的.do文档；处理后数据集.dta文件；数据处理工作小结.md文档
（包含数据处理操作和最后的描述性统计结果）
```

> 一些常规的数据处理操作（例如缩尾），即使不写，AI 有时候也会自己判断出需要执行，但结果不稳定。

Step 3：确认计划没问题后，开始执行

> 用时约 10 min

四、skill 简介和创建数据处理 skill

1. 什么是 Skills?

Skills（技能）是一组打包在指定文件夹中的【prompt + 程序 + 参考文件】

2. Skills 的结构

```
.claude/
└── skills/
    └── skillname/
        ├── SKILL.md        # 核心文件，必须有（含元数据和具体 prompt 描述）
        ├── scripts/        # 可选 - 程序脚本
        ├── assets/         # 可选 - 模板和资源
        └── references/     # 可选 - 参考文档（说明手册、规范文档）
```

3. 例子：skill-creator

以 `.claude/skills/skill-creator` 为例，其核心结构如下：

skill-creator 的工作原理与功能

功能：这是一个“用来创建技能的技能”。它可以协助用户从零开始搭建新技能、优化已有技能的触发词描述、执行自动化基准测试（Eval），并分析性能表现。

工作原理：

1. **识别指令，创建 skill**：通过识别用户诸如“创建新技能”的意图，触发 `SKILL.md` 中的系统提示词，创建 skill。
2. **执行脚本，测试和改进 skill**：调用 `scripts/` 中的 Python 脚本来测试 skill，然后根据 `assets/` 提供的模板呈现结果。

核心文件与文件夹的作用

- `SKILL.md`：核心定义文件。包含元数据（名称、技能简介、触发条件）以及指导大语言模型创建和优化其他技能的 Prompt 指示。
- `scripts/`：存放核心功能的 Python 脚本，用于执行自动化操作，例如：
  - `run_eval.py` / `run_loop.py`：用于执行技能测试与评估。
  - `generate_report.py` / `aggregate_benchmark.py`：用于收集测试结果并生成技能基准数据报告。
  - `improve_description.py`：帮助优化技能的触发描述词。
  - `package_skill.py`：打包和构建技能包。
  - `quick_validate.py`：快速验证技能结构的正确性。
- `assets/`：存放辅助执行的资源文件。如 `eval_review.html` 提供了展示技能测试评估结果的前端页面的模板。
- `references/`：提供背景及规范知识库，如 `schemas.md` 中保存了各种配置文件和所需 JSON/YAML 结构的 Schema 信息。
- `agents/`：对技能进行评估、对比和打分的三个 agent，在相应环节自动调用。

4. Skills 的优点

- 把标准化流程打包，可复用
- AI 只读取 SKILL.md 的元数据，判断要不要调用这个 skill，要调用时再读取 skill 里面的其他文件，节省 token 消耗和上下文空间

为什么要创建数据处理 skill?

让 AI 处理数据时，不用每次都说明剔除ST股、剔除金融业、指标要缩尾等等要求。

- 向 AI 说明的数据处理的具体要求（例如剔除哪些样本）
- 给 AI 制定工作规范（例如变量标签怎么写、最后输出什么文件）

5. 创建数据处理 skill

在 plan mode 下输入如下 prompt：

```
现在 @data/raw/ 里面的数据清洗完了。请你把清洗数据的流程打包成一个skill，放在当前项目文件夹。
参考 @file/plan.md, @file/data_processing_summary.md 的清洗流程和 @code/data_cleaning.do 的清洗代码，让skill实现以下功能：

1. 这个 skill 要自己探索数据结构（尽可能快速，不要扫描整个大型数据集，可以通过stata代码或者阅读数据里面的.txt说明文件来探索）
2. 然后要全面检查各种具体的数据预处理操作（包括但不限于：保留合并报表、保留年度数据、统一变量名、字符型转为数值型变量、
   剔除金融行业样本、剔除 ST 样本、剔除总资产为负等异常值、剔除上市不到一年样本、去重、缩尾等等）是否需要进行；
3. 尤其关注缺失值的情况。例如：合并数据集后，会不会某一个数据大量确实导致合并数据集大量缺失；计算某个指标时，
   会不会某个变量存在大量缺失值，导致这个指标存在大量缺失；
4. 如果不确定某个操作是否需要进行、怎么进行，要向我提问。
5. 根据我的需求，判断是只要处理单个数据集，还是要合并多个数据集
6. 根据我的需求，保留和计算我需要的变量
7. 清洗完成后，对重要的变量进行描述性统计

最终输出包括：数据处理的 .do 文档；处理后的 .dta 文件；数据处理工作小结 .md 文档（包含进行了哪些操作，以及最后的描述性统计）

用 stata 完成上述任务。用 stata mcp 调用 stata，不要用命令行调用。

因为每次用这个skill处理的数据结构可能不一样，这个skill考虑到的情况要尽可能全面，确保泛用性。

如果有什么我没提到但在其他数据清洗任务中常见的操作，请你补充。

另外，不知道上述功能全部放进一个skill比较好，还是分别放进几个不同的skill比较好。请你给出建议。
```

> 创建 skill 用时约 7 min；用 skill 清洗数据用时约 7 min

本次分享的内容手册链接：

> 本次分享涉及的全部资料：https://github.com/jasonli357/Claudecode_Stata
> 内容手册：https://jasonli357.github.io/Claudecode_Stata/
> 关于 Claude Code 的安装，可参考：
> https://jasonli357.github.io/Claudecode_Stata/body/11_references.html